

## AI광고 알고리즘

<https://brunch.co.kr/@kakao-it/84>

딥러닝 기술이 실제 광고 시스템에 적용하기 위해서는 확장 과정이 필요하다.

### 추천 시스템과 광고랭킹 시스템의 차이점

1. 추천 시스템은 보통 추천되는 아이템, 콘텐츠의 순서만 중요하고 상위 N 개의 아이템만 잘 추려내면 된다. 광고 랭킹은 추천 순서뿐 아니라, 정확한 추천 점수(pCTR(predicted click-through rate), eCPM(effective cost per mille))가 필요하다. 주로 eCPM에 따라서 광고의 노출 여부, 노출/클릭/전환에 따른 과금액이 산정된다.
2. 추천 순서와 함께 과금액을 결정해야 한다. 추천된 콘텐츠를 사용자가 조회했다고 해서 과금하지 않지만, 광고는 노출된 광고를 오디언스가 클릭하면 할인된 CPC(cost-per-click) 금액을 광고주에게 청구한다.
3. 높은 수준의 시스템 안정성이 요구된다. 광고는 회사의 매출과 직결돼서 장애 허용성(fault tolerance)이 보장돼야 하고 타임아웃도 없어야 한다. 또한 문제가 발생하였을 때 역추적도 가능해야 한다. 그러나 딥러닝은 속도와 안정성, 사후 문제 재현 및 해결 가능성이라는 측면에서 보수적이다.

### 광고랭킹 알고리즘

로지스틱 회귀모델

-CTR의 정의는 노출 횟수 대비 클릭 횟수의 비율이다.  $CTR = clicks/impressions$ , 1회 노출당 클릭될 확률을 구하는 문제와 같다. 로지스틱 회귀모델로 확률을 예측한다.

$$\Pr(y = 1 | \mathbf{x}, \mathbf{w}) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$$

$$\min_{\mathbf{w}} \frac{\lambda}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \log(1 + \exp(-y_i \mathbf{w}^T \mathbf{x}_i))$$

위의 손실 함수는 볼록성 최적화 문제로 보통 기울기 기반의 최적화 방식으로 쉽게 해결된다. 충분히 많은 학습 데이터 세트가 있다면 모델 가중치  $\mathbf{w}$ 는 쉽게 구할 수 있다. 그러나 배치(batch, 일괄)최적화로 가중치를 계산하는 것은 시간이 오래 걸려서 최신의 피드백(클릭/전환 데이터)을 바로 반영하지 못해서 확률적경사하강법(stochastic descent gradient, SGD)을 이용한다.

## 피쳐 데이터와 차원 축소

- 개별 오디언스 feature vector, 광고 feature vector, 지면 feature vector들의 상호작용효과를 반영하기 위해서 데카르트 곱 (Cartesian)을 취한다.
- 적게는 수백만 차원, 많게는 수억 차원의 feature 벡터가 만들어진다.
- 연산이 불가능하기에 데이터의 차원을 축소하는 기술이 필수이다.
- 야후 : 해싱 트릭, 페이스북: boosted decision tree, 구글 : 블룸 필터
- 카카오 : Cartesian product된 모든 feature로 무리가 있기에 유사한 오디언스나 지면을 클러스팅해 차원을 축소한다.

## 온라인 모델 업데이트, FTRL-Proximal(follow the regularized leader)

- 가장 일반적인 pCTR 예측모델
- 전처리 방법과 선택된 feature 종류에 따라 회사마다 예측 품질에 차이가 난다.
- 데이터의 변동성(매일 수억 건의 광고 요청, 노출)과 학습 효율을 고려해서 분할 정복방식을 사용해 시간 단위로 분할 학습과 통합 모델 구축 전략을 사용한다.

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta_t \mathbf{g}_t$$

온라인경사하강의 가중치 구하는 법은 위와 같다.  $\mathbf{g}_t$ 앞에 있는 단조 감소하는 기호는 학습 파라미터이다.

$$\mathbf{w}_{t+1} = \operatorname{argmin}_{\mathbf{w}} (\mathbf{g}_{1:t} \cdot \mathbf{w} + \frac{1}{2} \sum_{s=1}^t \sigma_s \|\mathbf{w} - \mathbf{w}_s\|_2^2 + \lambda \|\mathbf{w}\|_1)$$

- 첫째 항, t 시간까지 가장 작은 손실을 갖도록 한 leader들을 취해서 손실의 근사치를 구한다.
- 둘째 항, 새로운 가중치가 이전에 사용했던 가중치들에서 큰 변동이 없도록 제약하는 근접치
- 셋째 항, 정규화 파트이다.